

POSTECH — FIAP

Sistema de IA para Diagnóstico na Saúde Feminina

Tech Challenge — Fase 1

REPOSITÓRIO GIT

github.com/gabriel-lgomes/tech-challenge-1

Autor: gabriel-lgomes

Disciplinas: IA, Machine Learning e Visão Computacional

Linguagem: Python 3 · Jupyter Notebook

Dataset principal: Breast Cancer Wisconsin Diagnostic Dataset (Kaggle / UCI)

Dataset extra (CNN): Breast Ultrasound Images — BUSI (Kaggle)

1. Descrição do Desafio

Uma rede de hospitais e centros de saúde especializados no atendimento à mulher busca implementar um sistema inteligente de suporte ao diagnóstico e detecção de riscos, capaz de ajudar profissionais de saúde na identificação precoce de condições que afetam a segurança e saúde feminina.

Nesta primeira fase, o objetivo é criar a base do sistema com foco em **Machine Learning**, permitindo que dados médicos sejam analisados automaticamente para identificar padrões de risco relacionados à saúde das mulheres.

2. Datasets Escolhidos

Dataset Principal — Breast Cancer Wisconsin Diagnostic Dataset

Dataset público disponível no Kaggle (UCI Machine Learning Repository), contendo características extraídas de imagens de biópsia por aspiração com agulha fina (FNA) de massas mamárias.

Atributo	Valor
Total de amostras	569
Features	30 características numéricas por biópsia
Variável alvo	diagnosis : M (Maligno) ou B (Benigno)
Distribuição de classes	357 Benignos (62,7%) · 212 Malignos (37,3%)
Valores ausentes	Nenhum
Fonte	Kaggle — UCI Machine Learning Repository

Link para download:

<https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data>

As features representam 10 características do núcleo celular (raio, textura, perímetro, área, suavidade, compactidade, concavidade, pontos côncavos,

simetria e dimensão fractal), cada uma calculada em três estatísticas: média (`_mean`), erro padrão (`_se`) e pior valor (`_worst`).

Dataset Extra (CNN) — Breast Ultrasound Images (BUSI)

Dataset de ultrassonografias de mama utilizado na parte extra do projeto, com classificação em três categorias.

Atributo	Valor
Total de imagens	780 (excluindo máscaras de segmentação)
Classes	Benigno (437) · Maligno (210) · Normal (133)
Resolução	Variável — redimensionadas para 224×224 px
Fonte	Kaggle — Arya Shah

Link para download:

<https://www.kaggle.com/datasets/aryashah2k/breast-ultrasound-images-dataset>

3. Análise Exploratória (EDA)

Notebook: `notebooks/01_eda.ipynb`

Principais achados

- O dataset está limpo — sem valores ausentes ou duplicatas, exigindo pré-processamento mínimo.
- Leve desbalanceamento de classes (~63% benigno / ~37% maligno) — considerado na escolha das métricas.
- As features de **concavidade, perímetro e raio** apresentam maior separação entre classes.
- Alta multicolinearidade entre área, raio e perímetro — tratada na etapa de pré-processamento.
- Tumores malignos tendem a ser maiores, mais irregulares e com maior concavidade, consistente com a literatura clínica.

Gráficos gerados: distribuição de classes, histogramas por feature, boxplots por diagnóstico, matriz de correlação, ranking de correlação com o target e pairplot das top 5 features — disponíveis em `reports/figures/`.

4. Pré-processamento

Notebook: `notebooks/02_preprocessing.ipynb` · Módulo: `src/preprocessing.py`

Etapa	Ação	Resultado
Limpeza	Remoção das colunas <code>id</code> e <code>Unnamed: 32</code>	Sem colunas irrelevantes
Encoding	<code>B → 0, M → 1</code>	Target numérico
Multicolinearidade	Remoção de features com correlação > 0,95	Redução de redundância
Split	80% treino / 20% teste, estratificado	Proporção de classes preservada
Padronização	<code>StandardScaler</code> (fit no treino, transform no teste)	Features na mesma escala

O **StandardScaler** foi ajustado *exclusivamente* nos dados de treino e aplicado ao conjunto de teste, evitando vazamento de informação (*data leakage*) — prática essencial para garantir avaliação justa do modelo.

5. Modelagem

Notebook: `notebooks/03_modeling.ipynb` · Módulo: `src/evaluation.py`

Modelos treinados

Modelo	Justificativa
Regressão Logística	Baseline linear, interpretável e rápido. Permite verificar se a separação entre classes é linearmente possível.
Random Forest	Ensemble de árvores de decisão que captura relações não-lineares. Gera feature importance nativamente e é robusto a outliers.

Por que Recall é a métrica principal?

Falso Negativo = tumor maligno classificado como benigno → paciente vai para casa sem tratamento. Consequência clínica gravíssima.

Falso Positivo = tumor benigno classificado como maligno → exames adicionais desnecessários. Indesejável, mas manejável.

O **Recall** mede a capacidade do modelo de identificar todos os casos malignos. Deve ser maximizado neste contexto.

Validação cruzada (5-fold)

Antes da avaliação final, ambos os modelos foram validados com cross-validation em 5 folds para verificar estabilidade e ausência de overfitting.

Resultados no conjunto de teste

Os valores exatos são gerados na execução de `03_modeling.ipynb`. A tabela abaixo é preenchida automaticamente pelo notebook:

Modelo	Accuracy	Recall	Precision	F1-Score	AUC-ROC
Regressão Logística	Ver notebook 03_modeling.ipynb				

Modelo	Accuracy	Recall	Precision	F1-Score	AUC-ROC
Random Forest	Ver notebook 03_modeling.ipynb				

Gráficos gerados: comparação de métricas, matrizes de confusão, curva ROC, feature importance e SHAP (beeswarm, bar e waterfall).

6. Explicabilidade

Feature Importance (Random Forest)

O Random Forest calcula a importância de cada feature com base em quanto ela contribuiu para reduzir a impureza nas árvores. As features de **concave points**, **radius** e **perimeter** (nas estatísticas *worst* e *mean*) se destacaram como as mais relevantes para o diagnóstico.

SHAP (SHapley Additive exPlanations)

Além da importância global, o SHAP permite explicar **cada predição individualmente** — mostrando o quanto cada feature empurrou o resultado para maligno ou benigno em um caso específico. Foram gerados:

- **Beeswarm plot:** impacto de todas as features em todas as amostras simultaneamente
- **Bar plot:** importância média SHAP (mais robusta que a feature importance simples)
- **Waterfall plot:** explicação detalhada de um caso maligno individual

7. Extra — Diagnóstico por Imagem com CNN

Notebook: `notebooks/04_cnn.ipynb`

Objetivo

Além dos modelos com dados estruturados, foi implementada a parte extra do desafio: uma Rede Neural Convolucional (CNN) para classificação de imagens de ultrassonografia de mama utilizando Transfer Learning.

Arquitetura — VGG16 com Transfer Learning

Com apenas ~546 imagens de treino, treinar uma CNN do zero levaria a overfitting severo. A estratégia adotada foi o **Transfer Learning** com o VGG16 pré-treinado no ImageNet (1,4 milhão de imagens).

Componente	Descrição
Base	VGG16 pré-treinado no ImageNet (congelado na fase 1)
Cabeça customizada	GlobalAveragePooling2D → Dense(256, ReLU) → BatchNorm → Dropout(0.5) → Dense(3, Softmax)
Fase 1	Treino da cabeça — LR = 1e-3, até 25 épocas com EarlyStopping
Fase 2	Fine-tuning das últimas 4 camadas VGG16 — LR = 1e-5 (evita catastrophic forgetting)
Augmentation	Flip horizontal, rotação $\pm 10^\circ$, zoom $\pm 10\%$ — aplicado apenas no treino

Split

70% treino / 15% validação / 15% teste, estratificado por classe.

Resultados

Os valores exatos são gerados na execução de `04_cnn.ipynb`. Gráficos gerados: amostras por classe, curvas de aprendizado (fases 1 e 2), matriz de confusão e previsões individuais com percentual de confiança.

Complementaridade com o modelo ML

Os dois sistemas são **complementares**: a CNN captura informação espacial e textural das imagens de ultrassom, enquanto o Random Forest captura relações quantitativas das biópsias. Um sistema clínico completo combinaria ambos em um modelo ensemble.

8. Discussão Crítica

O modelo pode ser usado na prática?

Sim — como ferramenta de apoio à decisão médica, nunca como diagnóstico autônomo.

O desempenho no dataset Wisconsin é excelente (AUC-ROC próximo de 1,0), mas é preciso considerar:

- **Limitação do dataset:** coletado em condições controladas; performance em dados reais de hospitais pode ser inferior.
- **Falsos negativos existem:** mesmo com Recall alto, qualquer caso não detectado representa risco à vida da paciente.
- **O modelo deve apresentar scores, não diagnósticos:** "94% de probabilidade de malignidade" é mais útil e honesto do que "MALIGNO".
- **Explicabilidade é requisito clínico:** o SHAP permite que o médico valide a lógica do modelo antes de considerar a predição.
- **Validação externa necessária:** para uso clínico real, são necessárias validação em dados de outros hospitais, aprovação regulatória e integração com o sistema de prontuário existente.

O médico sempre tem a palavra final. O sistema proposto é uma ferramenta de triagem e priorização — não substitui a avaliação clínica especializada.

9. Organização do Repositório

Arquivo / Pasta	Conteúdo
<code>notebooks/01_eda.ipynb</code>	Análise exploratória completa com 6 gráficos
<code>notebooks/02_preprocessing.ipynb</code>	Pipeline de pré-processamento com 3 gráficos
<code>notebooks/03_modeling.ipynb</code>	Modelagem ML, avaliação e SHAP com 7 gráficos
<code>notebooks/04_cnn.ipynb</code>	[Extra] CNN VGG16 Transfer Learning com 4 gráficos
<code>src/preprocessing.py</code>	Funções reutilizáveis de pré-processamento
<code>src/evaluation.py</code>	Funções de avaliação e métricas
<code>reports/figures/</code>	20 gráficos gerados pelos notebooks (01–20)
<code>requirements.txt</code>	Dependências Python (inclui TensorFlow)
<code>README.md</code>	Documentação e instruções de execução

10. Como Executar

Pré-requisitos

- Python 3.10+ (recomendado via Miniconda)
- Conta no Kaggle para download dos datasets

Passos

1. Instalar dependências:

```
pip install -r requirements.txt
```

2. Baixar dataset principal (Wisconsin):

```
kaggle datasets download -d uciml/breast-cancer-wisconsin-data -p data/raw --unzip
```

3. **Baixar dataset extra (BUSI — necessário apenas para 04_cnn.ipynb):**

```
kaggle datasets download -d aryashah2k/breast-ultrasound-images-dataset -p data/raw/images --unzip
```

4. **Executar os notebooks em ordem:**

- `notebooks/01_eda.ipynb` — análise exploratória
- `notebooks/02_preprocessing.ipynb` — pré-processamento
- `notebooks/03_modeling.ipynb` — modelos ML e SHAP
- `notebooks/04_cnn.ipynb` — [extra] CNN com Transfer Learning

11. Links

Repositório Git

REPOSITÓRIO PÚBLICO NO GITHUB

<https://github.com/gabriel-lgomes/tech-challenge-1>

Vídeo de Demonstração

YOUTUBE / VIMEO — ATÉ 15 MINUTOS

<https://youtu.be/0seqcSZJnQg>